R語言 主題模型


王貿

國立臺灣大學行為與資料科學研究中心助理研究員 國立臺灣大學政治學系博士、兼任講師

maowang01@gmail.com

課程主題重點

- •常用的主題模型 (topic modeling)
- 改良版的主題模型
- 怎麼決定主題數?



https://www.tidytextmining.com/images/tmwr_0601.png

主題模型概覽

- •機器學習: 監督式學習vs. 非監督 式學習
- 從大量的文字資料 中,分析出其中討 論的主題。
- 主題模型就屬於「非監督式學習」




Figure source: Blei, D. M. (2012). Probabilistic topic models. Communications of the ACM, 55(4), 77-84.

主題模型是什麼?

- 應用「潛在狄利克雷分布」(Latent Dirichlet allocation, LDA)
- •主題模型是一個「分群」(clustering)演算法。
- 主題模型與一般的分群演算法(K-means, KNN)不同, 一個文件內有多個主題,所以是一種軟式(soft clustering)分群。

主題模型分析的流程




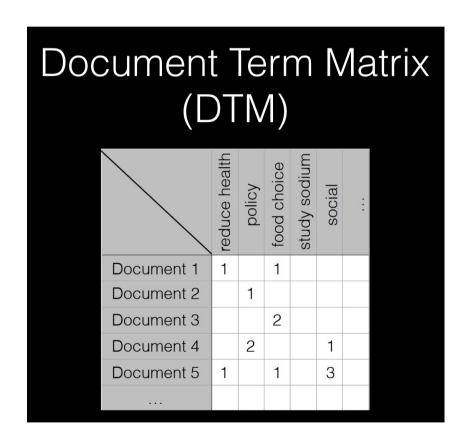
Figure 1. Application of LDA to a Corpus. *Note.* LDA = latent Dirichlet allocation.


Maier, D., Waldherr, A., Miltner, P., Wiedemann, G., Niekler, A., Keinert, A., Pfetsch, B., Heyer, G., Reber, U., Häussler, T., Schmid-Petri, H., & Adam, S. (2018). Applying LDA Topic Modeling in Communication Research: Toward a Valid and Reliable Methodology. *Communication Methods and Measures*, 12(2-3), 93-118. https://doi.org/10.1080/19312458.2018.1430754

主題模型的假設

- •一份文件有多個主題。
- 基於詞袋模型的假設,字詞的順序、文件的順序對於分析沒有影響。
- 必須先知道主題的數量。
- (最原始的主題模型)主題之間沒有關聯。


文字矩陣(DTM, TCM)





http://tommyjones.github.io/StatProgDC 2014 04 27/assets/player/KeynoteDHTMLPlayer.html#8


文字矩陣怎麼抽取主題



http://tommyjones.github.io/StatProgDC_2014_04_27/assets/player/KeynoteDHTMLPlayer.html#38

Structural Topic Model (stm)

- 優勢:納入文件的後設 資料(metadata),主 題之間**可以有關連**。
- 功能完整且強大。



其他學習資源

 Topic Modeling in R (https://www.datacamp.com/courses/topic-modeling-in-r)

實際應用範例

https://www.jstor.org/analyze/

